

Методы оптимизации

Лекция 11: Введение в проксимальные методы

Александр Катруца

Факультет инноваций и высоких технологий
Физтех-школа прикладной математики и информатики



13 ноября 2018 г.

На прошлой лекции

- ▶ Метод Ньютона

На прошлой лекции

- ▶ Метод Ньютона
- ▶ Квазиньютоновские методы

На прошлой лекции

- ▶ Метод Ньютона
- ▶ Квазиньютоновские методы
- ▶ Метод Barzilai-Borwein

На прошлой лекции

- ▶ Метод Ньютона
- ▶ Квазиньютоновские методы
- ▶ Метод Barzilai-Borwein
- ▶ Квазиньютоновские методы с ограниченной памятью

От градиентного спуска к методу проекции градиента

- ▶ Градиентный спуск

$$\begin{aligned}x_{k+1} &= \arg \min_x \left(\langle f'(x_k), x - x_k \rangle + \frac{L}{2} \|x - x_k\|_2^2 \right) \\&= \arg \min_x \left\| x - \left(x_k - \frac{1}{L} f'(x_k) \right) \right\|_2^2\end{aligned}$$

- ▶ Пусть есть ограничение вида $x \in C$, тогда

$$x_{k+1} = \arg \min_{x \in C} \left\| x - \left(x_k - \frac{1}{L} f'(x_k) \right) \right\|_2^2 = \pi_C \left(x_k - \frac{1}{L} f'(x_k) \right)$$

- ▶ Получили метод проекции градиента

Проекция и её свойства

Определение

Для данной точки $y \in \mathbb{R}^n$ решение следующей задачи

$$\min_{x \in C} \|x - y\|_2$$

называется проекцией точки y на множество C

Теорема

Если множество C выпукло и замкнуто, то проекция существует и единственна

Нерастягивающий оператор

Определение

Оператор f называется нерастягивающим, если

$$\|f(x) - f(y)\| \leq \|x - y\|,$$

то есть константа Липшица равна 1

Q: как называется оператор с константой Липшица меньше 1?

Теорема

Оператор проекции является нерастягивающим.

Доказательство

1. По свойству проекции, для любой точки y_1

$$\langle y_1 - \pi_C(y_1), x - \pi_C(y_1) \rangle \leq 0, \quad \forall x \in C$$

2. Пусть $x = \pi_C(y_2)$, тогда

$$\langle y_1 - \pi_C(y_1), \pi_C(y_2) - \pi_C(y_1) \rangle \leq 0$$

$$\langle \pi_C(y_2) - y_2, \pi_C(y_2) - \pi_C(y_1) \rangle \leq 0$$

3. Сложим

$$\langle \pi_C(y_2) - \pi_C(y_1), \pi_C(y_2) - \pi_C(y_1) \rangle \leq \langle \pi_C(y_2) - \pi_C(y_1), y_2 - y_1 \rangle$$

4. По неравенству КБШ

$$\|\pi_C(y_2) - \pi_C(y_1)\| \leq \|y_2 - y_1\|$$

Firmly non-expansiveness

Определение

Оператор f называется firmly non-expansive, если

$$\|f(x) - f(y)\|_2^2 \leq \langle f(x) - f(y), x - y \rangle$$

Теорема

Оператор проекции является firmly non-expansive:

$$\|\pi_C(x) - \pi_C(y)\|_2^2 \leq \langle \pi_C(x) - \pi_C(y), x - y \rangle$$

Сходимость

Лемма

Если x^* решение задачи, то $x^* = \pi_C(x^* - \alpha f'(x^*))$

Доказательство

1. $g^* \equiv f'(x^*)$
2. Общее условие оптимальности $\langle g^*, x - x^* \rangle \geq 0, \forall x \in C$
3. Свойство проекции $z = \pi_C(y)$

$$\langle z - y, x - z \rangle \geq 0, \forall x \in C$$

4. Подставим $z = x^*$ и $y = x^* - \alpha g^*$ и разделим на $\alpha > 0$

$$\langle g^*, x - x^* \rangle \geq 0$$

- ▶ $\|x_{k+1} - x^*\|_2^2 = \|\pi_C(x_k - \alpha f'(x_k)) - \pi_C(x^* - \alpha f'(x^*))\|_2^2 \leq \|x_k - x^* - \alpha(f'(x_k) - f'(x^*))\|_2^2 = \|x_k - x^*\|_2^2 + \alpha^2 \|f'(x_k) - f'(x^*)\|_2^2 - 2\alpha \langle f'(x_k) - f'(x^*), x_k - x^* \rangle$
- ▶ Если функция выпукла и дифференцируема, а также градиент Липшицев с константой L тогда

$$\langle f'(x) - f'(y), x - y \rangle \geq \frac{1}{L} \|f'(x) - f'(y)\|_2^2$$

- ▶ $\|x_{k+1} - x^*\|_2^2 \leq \|x_k - x^*\|_2^2 + \alpha(\alpha - \frac{2}{L}) \|f'(x_k) - f'(x^*)\|_2^2$
- ▶ $\alpha \leq \frac{2}{L} \rightarrow r_{k+1} \leq r_k \leq r_0$

- ▶ $f(x_{k+1}) \leq f(x_k) + \langle f'(x_k), x_{k+1} - x_k \rangle + \frac{1}{2} \|x_{k+1} - x_k\|_2^2 =$
 $f(x_k) + \langle f'(x_k), \pi_C(x_k - \alpha f'(x_k)) - \pi_C(x_k) \rangle + \frac{1}{2} \|x_{k+1} - x_k\|_2^2$
- ▶ $\|\pi_C(x_k - \alpha f'(x_k)) - \pi_C(x_k)\|_2^2 \leq$
 $\langle \pi_C(x_k - \alpha f'(x_k)) - \pi_C(x_k), -\alpha f'(x_k) \rangle$
- ▶ $-\alpha^{-1} \|x_{k+1} - x_k\|_2^2 \geq \langle f'(x_k), \pi_C(x_k - \alpha f'(x_k)) - \pi_C(x_k) \rangle$
- ▶ $f(x_{k+1}) \leq f(x_k) + \left(\frac{L}{2} - \frac{1}{\alpha}\right) \|x_{k+1} - x_k\|_2^2 =$
 $f(x_k) - \frac{L}{2} \|\pi_C(x_k - \alpha f'(x_k)) - x_k\|_2^2$
- ▶ $f_k \geq f_{k+1} + \frac{L}{2} \|\pi_C(x_k - \alpha f'(x_k)) - x_k\|_2^2$
- ▶ Складываем

$$f_0 - f^* \geq f_{k+1} - f^* + \frac{L}{2} \sum_{i=0}^k \|\pi_C(x_i - \alpha f'(x_i)) - x_i\|_2^2$$

- ▶ Левая часть конечна, значит ряд сходится и

$$\lim_{k \rightarrow \infty} \|\pi_C(x_k - \alpha f'(x_k)) - x_k\| = 0$$

- ▶ Получили сходимость!
- ▶ Если использовать неравенства-следствия выпуклости f , то можно показать сходимость вида $\mathcal{O}(1/k)$

Примеры множеств и проекции на них

- ▶ $C = \{x \mid a_i \leq x_i \leq b_i\} \rightarrow \pi_C(y) = \text{clip}_{[a_i, b_i]}(y)$
- ▶ $C = \{x \mid Ax = b\} \rightarrow \pi_C(y) = y - A^\top (AA^\top)^{-1}(Ay - b)$
- ▶ $C = \{x \mid \|x\|_2 \leq 1\} \rightarrow \pi_C(y) = y/\|y\|_2$
- ▶ $C = \mathbb{S}_+^n \rightarrow \pi_C(V) = \sum_{i=1}^n \max(0, \lambda_i) u_i u_i^\top$

Pro & Contra

Pro

- ▶ часто можно аналитически вычислить проекцию
- ▶ сходимость аналогична градиентному спуску в безусловной оптимизации
- ▶ обобщается на негладкий случай

Contra

- ▶ при больших n аналитическое вычисление проекции может быть слишком затратно
- ▶ при обновлении градиента может теряться структура задачи

Проксимальный метод

После дискретизации ОДУ

$$\frac{dx}{dt} = -f'(x(t))$$

вида

$$\frac{x_{k+1} - x_k}{\alpha} = -f'(\textcolor{red}{x}_{k+1}),$$

получим, что

$$\left(\frac{1}{2\alpha} \|u - x_k\|_2^2 + f(u) \right)' (x_{k+1}) = 0$$
$$x_{k+1} = \arg \min_u \left(f(u) + \frac{1}{2\alpha} \|u - x_k\|_2^2 \right) = \textit{prox}_{\alpha f}(x_k)$$

- ▶ Сильно выпуклая функция
- ▶ Единственный минимум

Неподвижная точка проксимального оператора

Теорема

Точка x^* является решением задачи тогда и только тогда, когда

$$x^* = \text{prox}_f(x^*)$$

Доказательство

1. Если x^* решение задачи, то $f(x) \geq f(x^*)$, тогда

$$f(x) + \frac{1}{2}\|x - x^*\|_2^2 \geq f(x^*) = f(x^*) + \frac{1}{2}\|x^* - x^*\|_2^2$$

2. x^* точка минимума функции $f(x) + \frac{1}{2}\|x - x^*\|_2^2$
3. Следовательно $x^* = \text{prox}_f(x^*)$
4. Из критерия первого порядка \bar{x} минимизирует $f(x) + \frac{1}{2}\|x - v\|_2^2$ iff $f'(\bar{x}) + (x - v) = 0$
5. $\bar{x} = v = x^* \rightarrow f'(x^*) = 0$

Интерпретация

Пусть f дважды дифференцируемы и сильно выпукла.

- ▶ Градиентный спуск как аппроксимация проксимального метода

$$x_{k+1} = \text{prox}_{\alpha f}(x_k) = (I + \alpha f')^{-1}(x_k) \approx x_k - \alpha f'(x_k) + o(\alpha), \quad \alpha \rightarrow 0$$

- ▶ Проксимальный метод для аппроксимации второго порядка
- $$\hat{f}(v) = f(x) + \langle f'(x), v - x \rangle + \frac{1}{2} \langle v - x, f''(x)(v - x) \rangle$$

$$\text{prox}_{\alpha \hat{f}}(x_k) = x_k - (f''(x_k) + (1/\alpha)I)^{-1} f'(x_k)$$

Случай разделения переменных

Если f имеет вид

$$f(x) = \sum_{i=1}^n f_i(x_i)$$

тогда

$$\text{prox}_f(v)_i = \text{prox}_{f_i}(v_i)$$

- ▶ Параллельное вычисление компонент
- ▶ Консенсусная форма постановки задачи

$$\min \sum_{i=1}^n f_i(x) \rightarrow \min \sum_{i=1}^n f_i(x_i), \text{ s.t. } x_1 = \dots = x_n$$

Проксимальный градиентный метод (PGM)

Рассмотрим выпуклую функцию $f(x)$ такую что

$$f(x) = h(x) + g(x),$$

- ▶ $h(x)$ выпуклая и дифференцируемая
- ▶ $g(x)$ выпуклая и может принимать бесконечные значения
 $g : \mathbb{R}^n \rightarrow \mathbb{R} \cup \{+\infty\}$

Тогда один шаг проксимального градиентного метода

$$x_{k+1} = \text{prox}_{\alpha_k g}(x_k - \alpha_k h'(x_k))$$

- ▶ Скорость сходимости $\mathcal{O}(1/k)$ для шага $\alpha_k \equiv \alpha \in (0, 1/L]$, где L константа Липшица для градиента f'
- ▶ Возможен адаптивный подбор L

Почему это работает?

$$\begin{aligned}x_{k+1} &= \arg \min_x \left(g(x) + \frac{1}{2\alpha_k} \|x - (x_k - \alpha_k h'(x_k))\|_2^2 \right) \\&= \arg \min_x \left(g(x) + h(x_k) + \langle h'(x_k), x - x_k \rangle + \frac{1}{2\alpha_k} \|x - x_k\|_2^2 \right)\end{aligned}$$

- ▶ Аналог градиентного спуска, но для композитной целевой функции
- ▶ Для негладкой функции f использование гладкой компоненты h повышает скорость сходимости

Частные случаи

- ▶ Если $g(x)$ индикаторная функция некоторого выпуклого множества G

$$g(x) = \begin{cases} 0 & x \in G \\ +\infty & x \notin G \end{cases}$$

PGM – метод проекции градиента

$$prox_g(y) = \arg \min_{u \in G} (\|y - u\|_2^2) \equiv \pi_G(y)$$

- ▶ Если $h \equiv 0$, тогда PGM – проксимальный метод
- ▶ Если $g \equiv 0$, тогда PGM – градиентный спуск

Ускоренный PGM (FISTA)

- ▶ Сходимость PGM аналогична сходимости градиентного спуска
- ▶ Известно, что такую сходимость можно ускорить
- ▶ Ускоренный PGM
 1. $y_1 = x_0, t_1 = 1, k = 1$
 2. $x_k = \text{prox}_{\alpha_k g}(y_k - \alpha_k h'(y_k))$
 3. $t_{k+1} = \frac{1 + \sqrt{1 + 4t_k^2}}{2}$
 4. $y_{k+1} = x_k + \left(\frac{t_k - 1}{t_{k+1}}\right)(x_k - x_{k-1})$
- ▶ Сходимость $\mathcal{O}(1/k^2)$
- ▶ Доказательство занимает страницу, см [тут](#)

Пример

$$\min_x \frac{1}{2} \|Ax - b\|_2^2 + \lambda \|x\|_1$$

- ▶ $h(x) = \frac{1}{2} \|Ax - y\|_2^2$
- ▶ $g(x) = \gamma \|x\|_1$

Soft thresholding


- ▶ $prox_{\alpha\|x\|_1}(x)_i = prox_{\alpha|\cdot|}(x_i)$
- ▶ $prox_{\alpha|\cdot|}(x_i) = \arg \min_u (|u| + 1/(2\alpha)(x_i - u)^2)$
- ▶ Аналитическое решение

$$prox_{\alpha|\cdot|}(x_i) = \begin{cases} x_i - \alpha & x_i \geq \alpha \\ 0 & |x_i| \leq \alpha \\ x_i + \alpha & x_i \leq -\alpha \end{cases}$$

- ▶ Векторизованный ответ

$$prox_{\alpha\|x\|_1}(x) = \mathbf{sign}(x)(|x| - \alpha)_+, \quad |x| = (|x_1|, \dots, |x_n|)$$

Сравнение



Направления исследований

- ▶ Неевклидовы расстояния в качестве прокс-слагаемого.
Зеркальный спуск
- ▶ Невыпуклые задачи определённой структуры
- ▶ Параллельные и распределённые реализации
- ▶ Различные способы дискретизаций ОДУ дают новые методы оптимизации, подробности [тут](#)